گزارش پروژه پایانی – فاز نهایی

استخراج رابطه در زبان فارسی با بررسی وابستگی‌های جهانی Seraji و PerDT

مبانی پردازش زبان و گفتار

استاد: دکتر بهروز مینایی بیدگلی

اعضای گروه:

دانیال بازمانده ۹۷۵۲۱۱۳۵

محمدحسین کریمیان ۹۷۵۲۱۴۶۸

فهرست مطالب

آدرس لینک درایو: (تمامی فایل‌های پروژه، علاوه بر گیت در درایو آپلود شده است.)

https://drive.google.com/drive/folders/17LecmpQV3i_pVE6_hKK9S3EdsvKKGbqA?usp=sharing

۱ هدف پروژه

هدف اصلی و غایی این پروژه، پیاده‌سازی یک سیستم هوشمند با استفاده از ابزارهای پردازش زبان‌های طبیعی و یادگیری ماشین، در جهت استخراج رابطه از جملات زبان فارسی است. موضوع پروژه انتخابی در واقع، ترکیبی از دو پروژه از لیست پروژه‌های داده شده است. چرا که در این پروژه، استخراج رابطه با استفاده از هر دو وابستگی جهانی Seraji و PerDT انجام شده است.

۲ مفهوم استخراج رابطه

در ابتدا، به توضیح و تفصیل مفهوم استخراج رابطه (Relation Extraction) در پردازش زبان‌های طبیعی می‌پردازیم.

عملیات استخراج رابطه در آموزش مدل‌های هوش مصنوعی مبتنی بر پردازش زبان طبیعی برای یادگیری روابط موجودیت‌های مختلف در یک متن برای تجزیه و تحلیل داده‌های استخراج‌شده انجام می‌شود. تکنیک‌های مختلفی برای انجام استخراج موجودیت وجود دارد، از تطبیق رشته ساده تا رویکردهای خودکار پیچیده‌تر.

منظور از استخراج رابطه مجموعه تسک‌هایی است که به استخراج روابط معنایی موجود در متون می‌پردازد. این روابط معمولا بین دو یا چند نهاد از یک نوع خاص (مانند شخص، سازمان، مکان و...) رخ می‌دهند و در تعدادی از دسته‌بندی‌های معنایی قرار می‌گیرند. (مانند متاهل، مجرد، استخدام‌شده و...) به عبارت بهتر، استخراج رابطه وظیفه‌ی پیش‌بینی صفات و روابط را برای موجودات و انتیتی‌های درون یک جمله دارد و مولفه‌ای کلیدی برای ساخت گراف‌های دانش است.

به عنوان نمونه، در زبان انگلیسی جمله‌ی «Barack Obama was born in Honolulu, Hawaii» را در نظر بگیرید. در این جمله هدف پیدا کردن رابطه‌ی «bornInCity» است. این رابطه بین دو موجودیت (Entity) «Barak Obama» و «Honolulu» وجود دارد.

البته در این پروژه ما با جملات و دادگان فارسی کار خواهیم داشت و به پیاده‌سازی استخراج رابطه در زبان فارسی پرداخته‌ایم.

به عنوان نمونه در زبان فارسی، جمله‌ی «دانیال بازمانده در شهر مشهد به دنیا آمد.» را در نظر بگیرید. هدف از تسک استخراج رابطه پیدا کردن رابطه‌ی «به دنیا آمدن» است. ما انتظار داریم پس از انجام موفق عملیات، آرگومان‌های این رابطه به دست آیند. در واقع، «دانیال بازمانده» و «شهر مشهد» آرگومان‌ها و «به دنیا آمد.» رابطه‌ای است که بین این دو آرگومان وجود دارد.

به عنوان نمونه‌ی دیگر می‌توان جمله‌ی «پاریس در فرانسه است.» را بیان کرد. در این جمله آرگومان‌ها «پاریس» و «فرانسه» هستند و «در» رابطه‌ای است که بین این دو موجودیت وجود دارد. همانطور که واضح است، الزامی به فعل بودن و معنی فعل دادن برای رابطه وجود ندارد.

انواع روش‌های مختلفی برای انجام عملیات استخراج رابطه وجود دارد:

۱) Rule-based RE
۲) Weakly Supervised RE
۳) Supervised RE
۴) Distantly Supervised RE
۵) Unsupervised RE

هر کدام از روش‌های فوق، مزایا و معایبی دارند که تفصیل آنها از حوصله‌ی این گزارش خارج است.

از کاربردهای مهم استخراج رابطه می‌توان به جستجوی ساختار یافته، تجزیه و تحلیل احساسات (Sentiment Analysis)، سیستم‌های پرسش و پاسخ (Question Answering) و خلاصه‌سازی متن می‌توان نام برد.

۳ وابستگی‌های جهانی

وابستگی جهانی (UD) پروژه‌ای است که در حال توسعه‌ی حاشیه‌نویسی از نظر زبانی سازگار برای بسیاری از زبان‌ها، با هدف تسهیل توسعه‌ی تجزیه‌کننده چندزبانه، یادگیری بین زبانی و تجزیه‌وتحلیل تحقیقات از منظر گونه‌شناسی زبان است. فلسفه‌ی کلی این است که فهرستی جهانی از مقوله‌ها و دستورالعمل‌ها برای تسهیل حاشیه‌نویسی ثابت ساختارهای مشابه در بین زبان‌ها فراهم کند.

به عبارت بهتر، وابستگی‌های جهانی (UD) چارچوبی برای حاشیه‌نویسی ثابت دستور زبان (بخش‌هایی از گفتار، ویژگی‌های صرفی و وابستگی‌های نحوی) در زبان‌های مختلف انسانی است. UD یک تلاش با بیش از ۳۰۰ مشارکت‌کننده است که نزدیک به ۲۰۰ درخت را از بیش از ۱۰۰ زبان تولید می‌کنند.

این طرح، تجزیه و تحلیل نحوی جملات را از نظر وابستگی‌های دستور زبان مربوطه تولید می کند. هر وابستگی از یک تابع نحوی مشخص می‌شود که روی لبه‌ی وابستگی (فلش در شکل) نشان داده می‌شود.

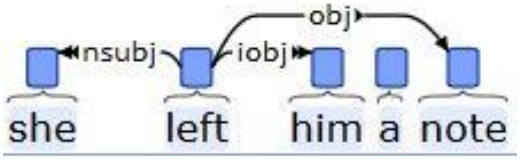

برای موفقیت یک UD خوب، موارد زیر باید رعایت شوند:

- در زمینه‌ی تحلیل زبانی برای هر زبان رضایت‌بخش و مناسب باشد.
- برای گونه‌شناسی زبانی خوب باشد. به‌عنوان مثال، زمینه‌ای مناسب برای ایجاد موازی زبانی بین زبان‌ها و خانواده‌های زبانی فراهم کند.
- برای حاشیه‌نویسی سریع و ثابت توسط یک حاشیه‌نویس انسانی مناسب باشد.
- به راحتی توسط یک غیر زبان شناس قابل درک و استفاده باشد.
- برای تجزیه کامپیوتری با دقت بالا مناسب باشد.
- به خوبی از وظایف درک زبان پایین دستی پشتیبانی کند. (استخراج رابطه، درک مطلب، ترجمه ماشینی و...)

در زبان فارسی، وابستگی جهانی حاوی داده‌هایی از چندین بانک درختی (Treebank) است که توسط تیم‌های مختلف در زمان‌های مختلف و با ابزارهای تبدیل متفاوت ایجاد شده‌اند. در حال حاضر دو وابستگی جهانی مهم در زبان فارسی وجود دارند: Seraji و PerDT.

۳/۱ وابستگی جهانی *Seraji*

بانک درختی وابستگی جهانی فارسی (Persian UD) نسخه تبدیل‌شده‌ی بانک درختی وابستگی فارسی اوپسالا (UPDT) است. (سراجی، ۲۰۱۵). این بانک درختی، طرح حاشیه‌نویسی اصلی خود را بر اساس وابستگی‌های تایپ‌شده‌ی استنفورد دارد. (دی مارنف و همکاران، ۲۰۰۶؛ د مارنف و منینگ، ۲۰۰۸)

این طرح برای زبان فارسی گسترش یافت تا روابط نحوی خاص زبان را در بر گیرد که نمی‌توانست توسط طرح اولیه توسعه‌یافته برای انگلیسی پوشش داده شود. این بانک درختی شامل ۶۰۰۰ جمله‌ی متون مکتوب با تنوع دامنه بزرگ، از نظر ژانرهای مختلف (شامل مقالات روزنامه، داستان ها، توضیحات فنی و اسناد در مورد فرهنگ و هنر) و نشانه‌گذاری است. تغییرات در نشانه‌گذاری به دلیل تغییرات املایی کلمات مرکب و عبارات ثابت در زبان است.

UPDT اصلی توسط مژگان سراجی و زیر نظر جواکیم نیور و کارینا جهانی در دانشگاه اوپسالا ساخته شد. جدای از طرح حاشیه‌نویسی جهانی و قوانین کلی در *UD*، *UD* فارسی و *UPDT* در نشانه گذاری تفاوت بیشتری دارند. تمام کلمات حاوی کلیدهای تقسیم‌نشده (قطعات ضمایر و کوپولا) که با برچسب‌های پیچیده در *UPDT* حاشیه نویسی شده اند، از کلیدواژه ها جدا شده‌اند و برچسب‌های متمایز در *UD* فارسی دریافت کرده‌اند.

تبدیل *UPDT* به وابستگی های جهانی به صورت نیمه خودکار انجام شده است. در این فرآیند، از یک اسکریپت تبدیل برای معکوس کردن سر و روابط وابسته در تعدیل‌کننده حرف اضافه (prep) و مفعول یک حرف اضافه (pobj) استفاده کردیم. علاوه بر این، ما از اسکریپت‌های دیگری که برای فارسی طراحی شده‌اند، برای جدا کردن انواع کلیتیک‌ها از میزبان خود استفاده کرده‌ایم. متعاقباً قوانین مختلفی را برای بازنویسی تگ‌های درشت قسمت گفتار و برچسب‌های وابستگی اضافه کردیم.

۳/۲ وابستگی جهانی *PerDT*

بانک درختی وابستگی جهانی فارسی (PerUDT) حاصل پوشش خودکار بانک درخت وابستگی فارسی (PerDT) با اصلاحات دستی گسترده است که توسط محمدصادق رسولی، پگاه صفری، امیرسعید مولودی و علیرضا نوریان در سال ۲۰۱۳ پیاده‌سازی شده است.

بانک درختی اصلی شامل ۲۹ هزار جمله است که از متون فارسی معاصر در ژانرهای مختلف از جمله: اخبار، مقالات دانشگاهی، مقالات مجلات و داستان‌ها نمونه برداری شده است. این بانک درختی بر اساس یک طرح زبان خاص حاشیه‌نویسی شد و تبدیل خودکار آن شامل سه مرحله اصلی بود:

۱) بازبینی توکن‌سازی (Revising Tokenization)
۲) نگاشت POS (POS Mapping)
۳) نگاشت وابستگی (Dependency Mapping)

در مرحله‌ی نشانه‌گذاری، به منظور جداسازی عطف های چند کلمه‌ای افعال ساده که به صورت یک نشانه در PerDT گروه بندی شده اند، از دستورالعمل های موجود برای یافتن خودکار افعال اصلی پیروی کردیم. هم‌چنین به طور خودکار کلیدهای ضمیری را جدا کردیم.

در مرحله تبدیل *POS*، ما از آخرین تگر فارسی NER مبتنی بر BERT (Taher et al., 2020) با اصلاحات دستی برای گسترش فراخوان استفاده کردیم. از طریق هفت موجودیت مختلف شناسایی‌شده توسط برچسب‌گذار، از Person و Location برای علامت‌گذاری برچسب‌های PROPN استفاده کردیم. در مجموع، PerDT شامل ۴۳ رابطه نحوی بدون نگاشت مستقیم است. حروف ربط از ابتدای جمله تا انتها مرتب شده اند و مهمتر از آن، حروف اضافه به عنوان سر عبارات اضافه و افعال کمکی به عنوان سر جملات قرار می‌گیرند.

بنابراین ما ترتیب حروف ربط را از انتها به ابتدا از طریق یک اسکریپت و قواعد مناسب برای تبدیل هر نوع رابطه به نسخه UD آن به درستی مرتب کردیم. در طول کل فرآیند و در پایان هر مرحله، نتایج را بررسی کردیم و در صورت نیاز اصلاحات دستی را اعمال کردیم.

۳/۳ مقایسه‌ی وابستگی‌های جهانی

در تصویر زیر، جدولی از مقایسهٔ «درخت بانک وابستگی فارسی اوپسالا» با هریک از وابستگی‌های جهانی Seraji و PerDT ارائه داده است. مبنا را بر وابستگی‌های جهانی می‌گذاریم و نشان می‌دهد هر برچسب اجزای سخن در وابستگی جهانی چه معادلی در پروژه‌ی دانشگاه اوپسالا (Seraji) و «پروژه‌ی دادگان وابستگی زبان فارسی (PerDT)» دارد.

Dad Sub-Tag Fa	Dad Sub-Tag	Dad Fa Name	Dad Tag	Seraji Fa Name	Seraji Name	Seraji Tag	Persian Name	UD Name	UD Tag	UD Num
صفت مطلق	AJP	صفت	ADJ	صفت	Adjective	ADJ	صفت	adjective	ADJ	1
صفت عالی	AJSUP			صفت عالی	Superlative adjective	ADJ_SUP				
صفت تفضیلی	AJCM									
صفت شمارشی پسین	POSNUM									
				صفت مفعولی	Participle adjective	ADJ_INO				
				صفت ندا	Vocative adjective	ADJ_SUP				
				صفت مقایسه‌ای	Comparative adjective	ADJ_CMPR				
	ندارد	حرف اضافه پیشین	PREP	حرف اضافه پیشین	Preposition	P	حرف اضافه	adposition	ADP	2
قید مختص	SADV	قید	ADV	قید	Adverb	ADV	قید	adverb	ADV	3
				قید مقایسه	Adverb of Comparison	ADV_COMP				
				قید استفهام	Adverb of Interrogation	ADV_I				
				قید مکان	Adverb of Location	ADV_LOC				
				قید نفی	Adverb of Negation	ADV_NEG				
				قید زمان	Adverb of time	ADV_TIME				
		شبه جمله	PSUS							
		جزء دستوری	PART							
وجهی	MODL	فعل	V	فعل کمکی	Auxiliary Verb	V_AUX	فعل کمکی	auxiliary	AUX	4
		نقش نمای همپایگی	CONJ	حرف ربط	Conjunction	CON	حرف ربط هم پایه ساز	coordinating conjunction	CCONJ	5
صفت تعجبی	EXAJ	پیش توصیف گر	PREM	مشخصگر	Determiner	DET	مشخصگر	determiner	DET	6
صفت پرسشی	QUAJ									
صفت اشاره	DEMAJ									
صفت مبهم	AMBAJ									
نقش نمای ندا پیشین	PRADR	نقش نمای ندا	ADR	صوت و حرف ندا	Interjection	INT	صوت و حرف ندا	interjection	INTJ	7
نقش نمای ندا پسین	POSADR									
		شبه جمله	PSUS							
جاندار	ANM	اسم	N				اسم	noun	NOUN	8
بی جان	IANM									
				Plural noun	اسم جمع	N_PL				
				Singular noun	اسم مفرد	N_SING				
				Vocative noun	اسم ندا	N_VOC				
		شاخص	IDEN							
		صفت شمارشی پیشین	PRENUM	Numeral	عدد	NUM	عدد	numeral	NUM	9
		صفت شمارشی پسین	POSNUM							
		حرف اضافه پسین	POSTP	Accusative marker	علامت مفعولی	CLITIC	ادات	particle	PART	10
		ضمیر	PR	Pronoun	ضمیر	PRO	ضمیر	pronoun	PRON	11
ضمیر شخصی جدا	SEPER									
ضمیر شخصی پیوسته	JOPER									
ضمیر اشاره	DEMON									
ضمیر پرسشی	INTG									
ضمیر بازتابی مشترک	CREFX									
ضمیر بازتابی غیرمشترک	UCREFX									
ضمیر متقابل	RECPR									
ندارد				ندارد			اسم خاص	proper noun	PROPN	12
		علامت نگارشی	PUNC	Delimiter	جداکننده	DELM	علامت نگارشی	punctuation	PUNCT	13
		نقش نمای وابستگی	SUBR	حرف ربط	Conjunction	CON	حرف ربط وابسته‌ساز	subordinating conjunction	SCONJ	14
ندارد				نماد	Symbol	SYM	نماد	symbol	SYM	15
		فعل	V	فعل امری	Imperative verb	V_IMP	فعل	verb	VERB	16
				فعل زمان گذشته	Past tense verb	V_PA				
				فعل گذشته کامل	Past participle verb	V_PP				
				فعل ربطی	Verb copula	V_COP				
				فعل زمان حال	Present tense verb	V_PRS				
				فعل شرطی (التزامی)	Subjunctive verb	V_SUB				
معلوم	ACT									
مجهول	PASS									
وجهی	MODL									
		شبه جمله	PSUS	واژه خارجی	Foreign word	FW	دیگر واژه ها	other	X	17

۴ فریم‌ورک *Predpatt*

Predpatt مخفف عبارت Predicate-Argument Extraction from Universal Dependencies یک کتابخانه‌ی قدرتمند توسعه‌یافته است که به عنوان چارچوبی از الگوهای استخراج گزاره (Predicate)-آرگومان قابل توسعه، قابل تفسیر و زبان خنثی ارائه می‌شود. PredPatt عملیات تجزیه نحوی عمیق پروژه‌ی وابستگی جهانی را به یک لایه معنایی کم‌عمق اولیه پیوند می‌دهد. این می‌تواند پایه‌ای برای لایه‌بندی آینده‌ای از حاشیه‌نویسی‌های معنایی در بالای درخت‌های وابستگی جهانی باشد. هم‌چنین به‌طور جداگانه می‌تواند به‌عنوان یک مؤلفه زبان‌شناختی به‌خوبی از سازوکار «IE Universal» در نظر گرفته شود.

این کتابخانه در سراسر زبان‌های دنیا کار می کند. *Predpatt* با سایر سیستم های برجسته‌ی Open IE مقایسه شده است و نتایج به‌دست‌آمده نشان می‌دهد که PredPatt به بهترین دقت و یادآوری دست می یابد.

کاربرد اصلی *PredPatt* استخراج روابط از جملات ورودی به آن است. به این صورت که تلاش می‌کند با استفاده از الگوریتم‌های قوی پیاده‌سازی‌شده، آرگومان‌ها و رابطه‌های موجود در یک جمله را به دست آورد. با استفاده از این آرگومان‌ها و رابطه‌ها می‌توان گراف معنایی (*Semantic Graph*) مرتبط با جملات را ترسیم کرد.

به عنوان نمونه می‌توان کاربرد آن را در زبان انگلیسی مشاهده کرد. همانطور که مشخص است، آرگومان‌های *a* و *b* و *c* از جمله به دست آمده است که هرکدام از آرگومان‌ها نقش *POS* مخصوص به خود را دارند.

?a extracts ?b from ?c
?a: PredPatt
?b: predicates
?c: text
?a gave ?b to ?c
?a: Chris
?b: the book
?c: Pat

به عنوان نمونه‌ی دیگر در جملات زبان فارسی داریم:

علی دایی بازیکن فوتبال بازنشسته تیم ملی ایران و باشگاه پرسپولیس است.

a? بازیکن *b*? است.

a?: علی دایی

b?: فوتبالِ (بازنشسته تیم ملی ایران و باشگاه پرسپولیس)

در مثال بالا، *a* و *b* آرگومان‌های ما هستند. یعنی در این جمله، علی دایی و فوتبال آرگومان‌های رابطه محسوب می‌شوند. هم‌چنین کلمه‌ی «بازیکن» به عنوان رابطه‌ی بین این دو آرگومان محسوب می‌شود.

نکته مهم: برای تشخیص اینکه کدام کلمه به عنوان رابطه درنظر گرفته شود، ما همیشه تمام کلماتی که بین دو آرگومان می‌آیند را به عنوان رابطه‌ی آن دو آرگومان در نظر می‌گیریم. برای استناد به درستی این کار، از مقاله‌ی Farsbase bkp نوشته دکتر مینایی بهره گرفته‌ایم.

سهراب سپهری شاعر، نویسنده و نقاش اهل ایران بود.

a? شاعر بود

a?: سهراب سپهری

a? نویسنده

a?: سهراب سپهری

a? نقاش *b*?

a?: سهراب سپهری

b?: اهل ایران

مطابق توضیحات قبل، دو آرگومان «سهراب سپهری» و «اهل ایران» داریم و کلمات «شاعر»، «نویسنده» و «نقاش» نیز به عنوان روابط بین این آرگومان‌ها در نظر گرفته می‌شوند. پس سه رابطه در مجموع داریم.

۵ آماده‌سازی دیتاست

۵/۱ مرحله اول: جمع‌آوری داده‌ها

به عنوان اولین فاز، احتیاج به جمع‌آوری مقدار زیادی داده داریم. زیرا برای دستیابی به هدف نهایی، نیاز به تعداد جملات زیادی داریم تا عملیات آموزش و آزمون را روی آنها انجام دهیم و مدل خود را بهبود دهیم. به عنوان سورس و مرجع از دیتاست سایت جامع ویکی‌پدیا استفاده می‌کنیم.

برای دستیابی به داده‌ها و جملات موجود در این وبسایت بزرگ، به Crawl کردن آنها می‌پردازیم. برای این کار، با استفاده از کتابخانه‌ی *BeautifulSoup* اقدام به خزش در فایل‌های *html* می‌کنیم و اطلاعات را مرحله به مرحله استخراج می‌کنیم. توضیحات مربوط به این بخش به طور کامل در گزارش فاز قبلی آمده است و اینجا به طور خلاصه به مراحل انجام کار اشاره می‌کنیم و به همین بسنده می‌کنیم.

در گام اول، ابتدا تمامی الفباهای موجود در این وبسایت را به دست می‌آوریم:

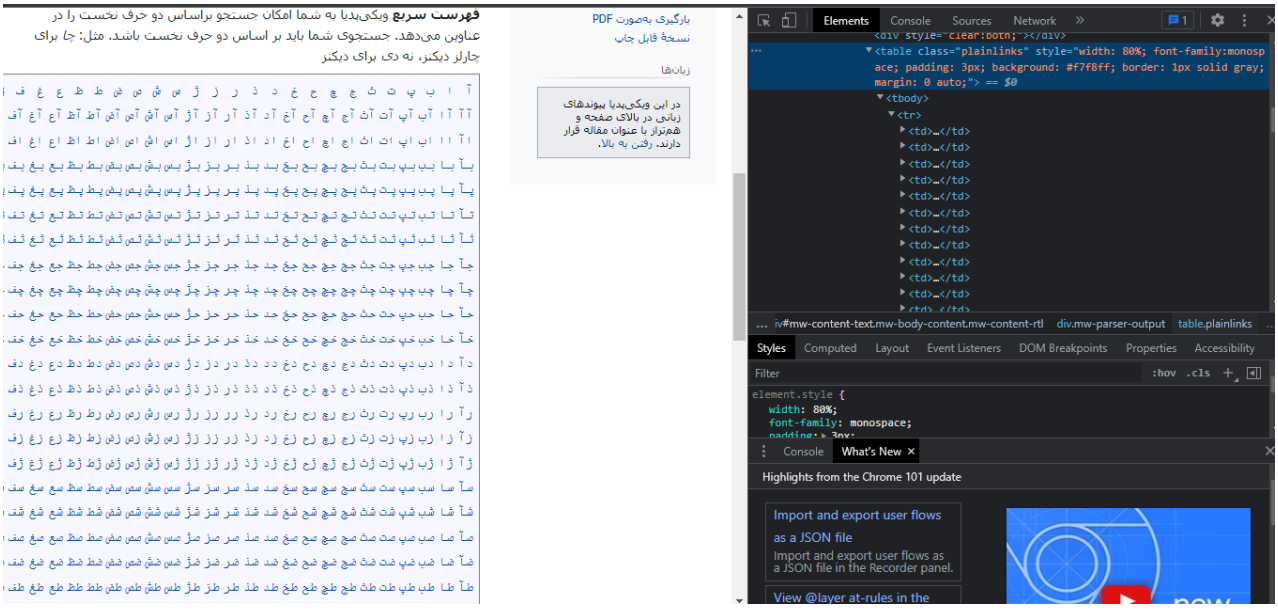

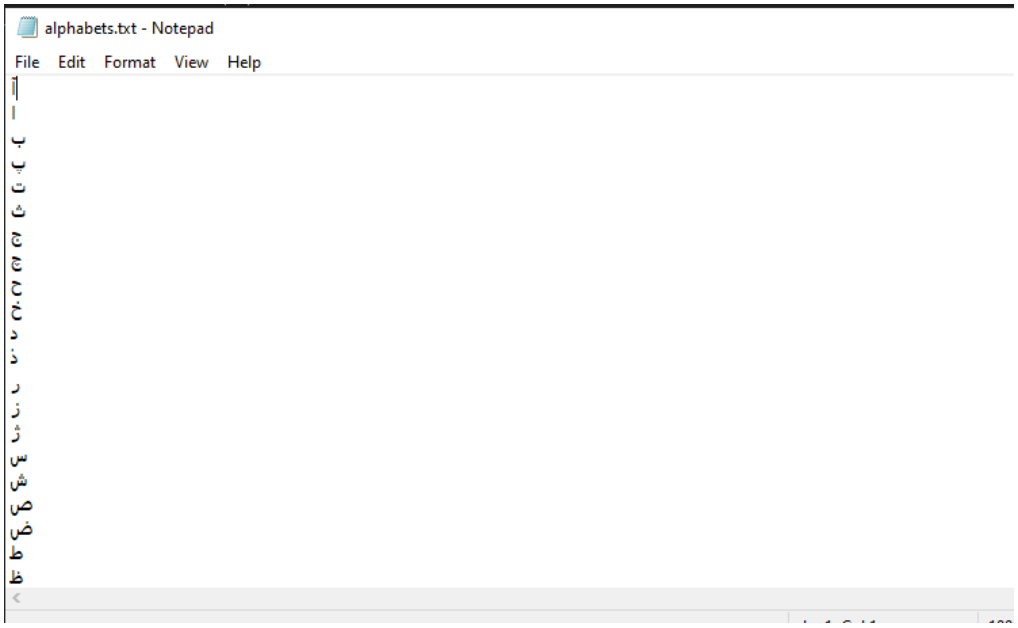

در گام بعد، اقدام به دستیابی به تمام موضوعاتی که با آن حروف شروع می‌شوند، می‌کنیم. به این خاطر که داده‌های مورد نیاز ما حداکثر سی هزار جمله می باشد، فقط موضوعاتی که در صفحه اول حروف هستند را در نظر می گیریم و همچنین حروفی از فهرست که بیش از یک حرف دارند را هم حذف می کنیم.

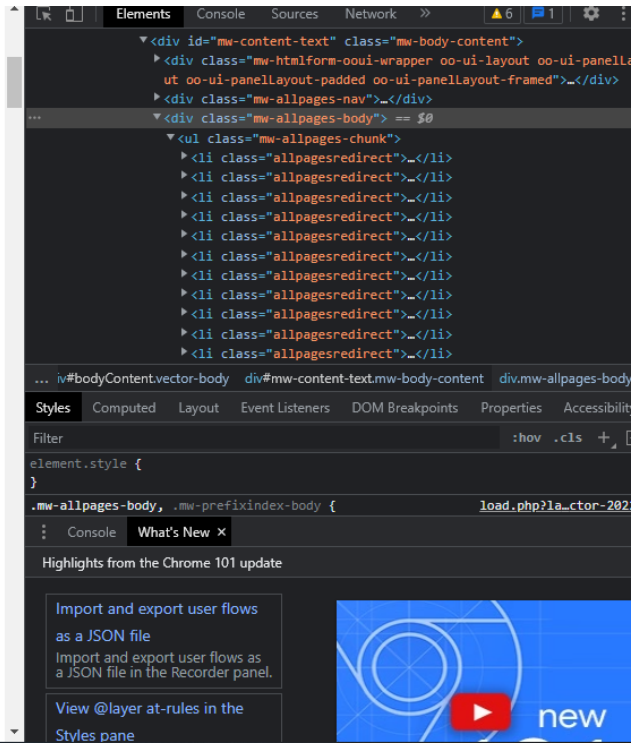

حال با ایجاد یک درخواست (*request*) به هرکدام از لینک‌های موجود، اقدام به دستیابی به جملات موجود در هر صفحه می‌کنیم. برای هر صفحه یک موجودیت *json* شامل id، title و subject درست می‌کنیم.


```
{
    "id": 1,
    "title": "الف",
    "text": "ل اولین حرف الفبای فارسی و الفبای عربی و سایر ابجدهای استفاده‌شده توسط زبان‌های سامی است. این
    ل الفبایی هم در نقش یکی از حروف واکهٔ بلند (مصوت بلند) است که گاه \n.حرف در زبان فارسی شروع کننده خیلی از اسم هاست
    ،به صورت (ا) در کلماتی چون: آب، باد و دریا است. و هم در نقش تلفظ همزه به کمک حرف‌های واکه به کار می‌رود، مانند: آبر
    انسان و اُستاد (با حروف واکه کوتاه فتحه - کسره و ضمّه) و مانند: آب (الف اول در اصل=اآب)، او، این (با حروف واکه بلند)
    آ یا الف مَدّدار (به عربی: ألف ممدودة) است که آن را با همزه یا الف یکی \n.در لغتنامه‌ها «ا.» مخفف اسم است \n.است
    این نشانه با نام‌های مختلفی \n.می‌شناسند، اما در حقیقت حرفِ جداگانه‌ای است. این حرف تغییر شکل‌یافتهٔ حرف عبری א است
    فرهنگ معین در آغاز فصل «آ، ا» نوشته شده است: « «آ» و «ا» را در الفبای فارسی یک حرف به‌حساب \n:معرفی شده است، از جمله
    آورند، اما درحقیقت دو حرف جداگانه‌اند،...» در لغتنامهٔ دهخدا نیز آمده است: «آ. (حرف) الف لیّنه، مقابل همزه یا الف
    متحرکه، حرف اول است از حروف هجا، و در حساب جُمَل آن را به «یک» دارند.». اما این نشانه درحقیقت ترکیبی از دو حرف از
    الفبای فارسی است: «ا» به‌عنوان صامت که شکلی از أشکال همزه است، و «ا» که مصوت بدون نامی است از مصوت‌های شش‌گانهٔ خط
    فارسی. اما به اشتباه در دستور خطّ فارسی مصوب فرهنگستان زبان و ادب فارسی، در «جدول ۱. نشانه‌های خطّ فارسی، نشانه‌های
    اصلی»، سی‌وسه نشانه معرفی شده است و این نشان «آ» جزو نشانه‌های سی‌وسه‌گانه‌ای که الفبای فارسی را تشکیل می‌دهند آورده
    نشده است. تمام مطالب این بخش از لغتنامهٔ دهخدا، مادهٔ «آ»، نقل شده است؛ مگر آن‌که از منبع دیگری نام برده شده باشد.\n "
},
```

۵/۲ مرحله دوم: پاکسازی داده‌ها

در این مرحله با استفاده از کتابخانه‌ی هضم که همانند *nltk* در زبان انگلیسی است، اقدام به نرمال‌سازی هرکدام از جملات می‌کنیم. سپس برای به دست آوردن کلمات، با *stemming* ریشه اصلی آن ها را به دست می آوریم و در نهایت چک می کنیم که این کلمات بین *stop words* های زبان فارسی هستند یا خیر و اگر در فایل *stop words* نبود، آن را در لیست کلمات در فایل *words.txt* می نویسیم که در شکل زیر این فایل را می بینیم.

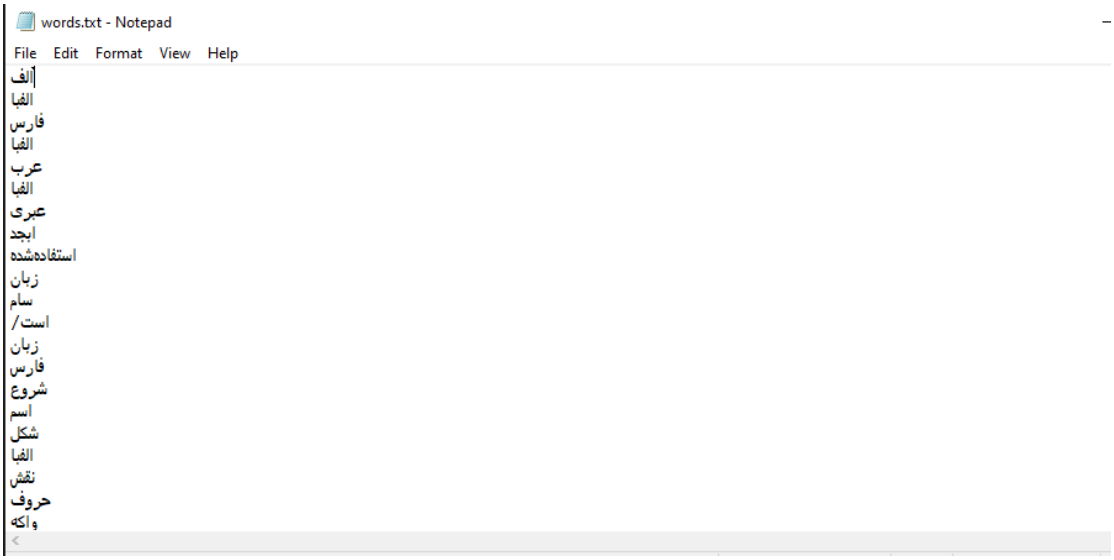

۵/۳ مرحله سوم: پردازش آماری داده‌ها

در نهایت تمامی جملات به دست آمده را جدا می‌کنیم و در فایل *sentences.json*، همراه با آیدی و موضوع آن می نویسیم. از این جملات به عنوان دادگان اصلی در جهت استفاده در بخش‌های بعدی استفاده می‌کنیم.

تعداد جملات نهایی ۳۱۳۶۳ عدد می‌باشند که برای استفاده در وابستگی‌های جهانی مورد استفاده خواهند بود.

همچنین برای این که هر کلمه را با تعداد تکرارش داشته باشیم، یک دیکشنری تعریف می کنیم و هر بار که کلمه ای تکرار شد یکی به تعداد تکرار آن اضافه می کنیم و در نهایت آن را پس از *sort* کردن بر اساس تکرار بیشتر، در فایل *count.txt* ذخیره می کنیم.

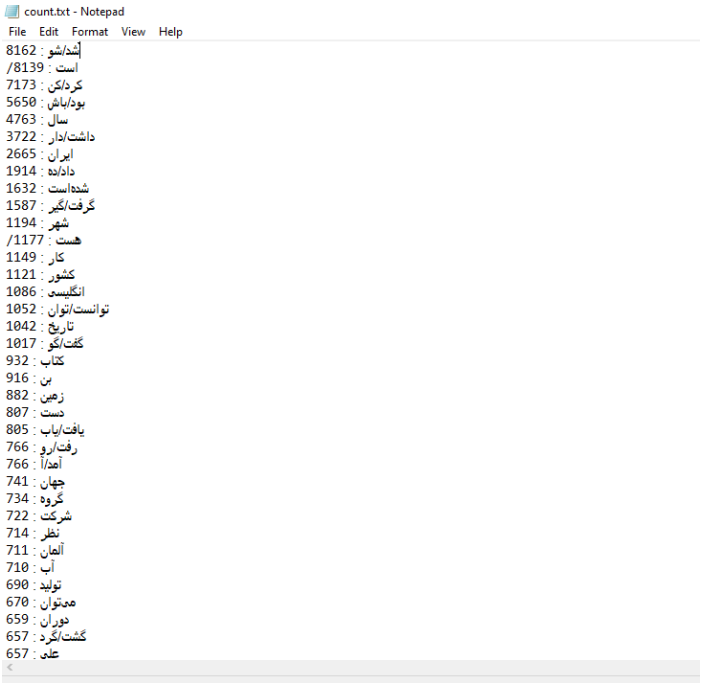

نمودار فراوانی کلمات در زیر قابل مشاهده است:

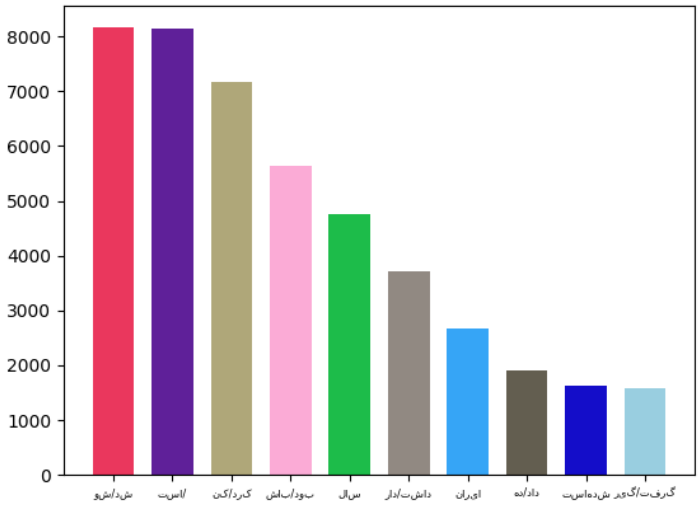

۶ پیاده‌سازی فرایند استخراج رابطه

در این مرحله، اقدام به پیاده‌سازی سیستمی در جهت استخراج روابط موجود در جملات می‌کنیم. به نحوی که سیستم مربوط با دریافت یک یا تعدادی از جملات و هم‌چنین انتخاب نوع وابستگی جهانی (*Seraji* یا *PerDT*)، آرگومان‌های مربوطه و رابطه‌ی بین آرگومان‌ها را استخراج کند.

توجه: لازم به ذکر است در جهت توسعه‌ی یک سیستم نرم‌افزاری مطلوب در جهت راحتی مشتریان و *UI/UX* بهتر، اقدام به پیاده‌سازی این سیستم در قالب یک سیستم *client/server* کردیم و تلاش کردیم صفحه‌ای به عنوان رابط کاربری برای کاربر نمایش دهیم تا به واسطه‌ی *API* های سرور بتواند به استخراج آرگومان‌های مربوطه از جملات دلخواه خود بپردازد. پیاده‌سازی این بخش نرم‌افزاری جزو قسمت‌های پروژه نبوده است.

برای بخش سرور از فریم‌ورک *Django* مربوط به زبان پایتون استفاده کرده‌ایم. با استفاده از این فریم‌ورک، یک صفحه طراحی کرده‌ایم که کاربر بتواند با ورودی متن مربوطه و انتخاب نوع وابستگی جهانی و انتخاب گزینه *Submit*، نتیجه را مشاهده کند.

هم‌چنین اقدام به پیاده‌سازی *API* های مربوطه برای هر دو وابستگی جهانی پرداختیم که بتوان از دیوایس‌ها و برنامه‌های دیگر نیز با استفاده از این *API* ها ارتباط برقرار کرد.

نمونه‌ای از فرایند استخراج رابطه با استفاده از وابستگی جهانی *Seraji*:

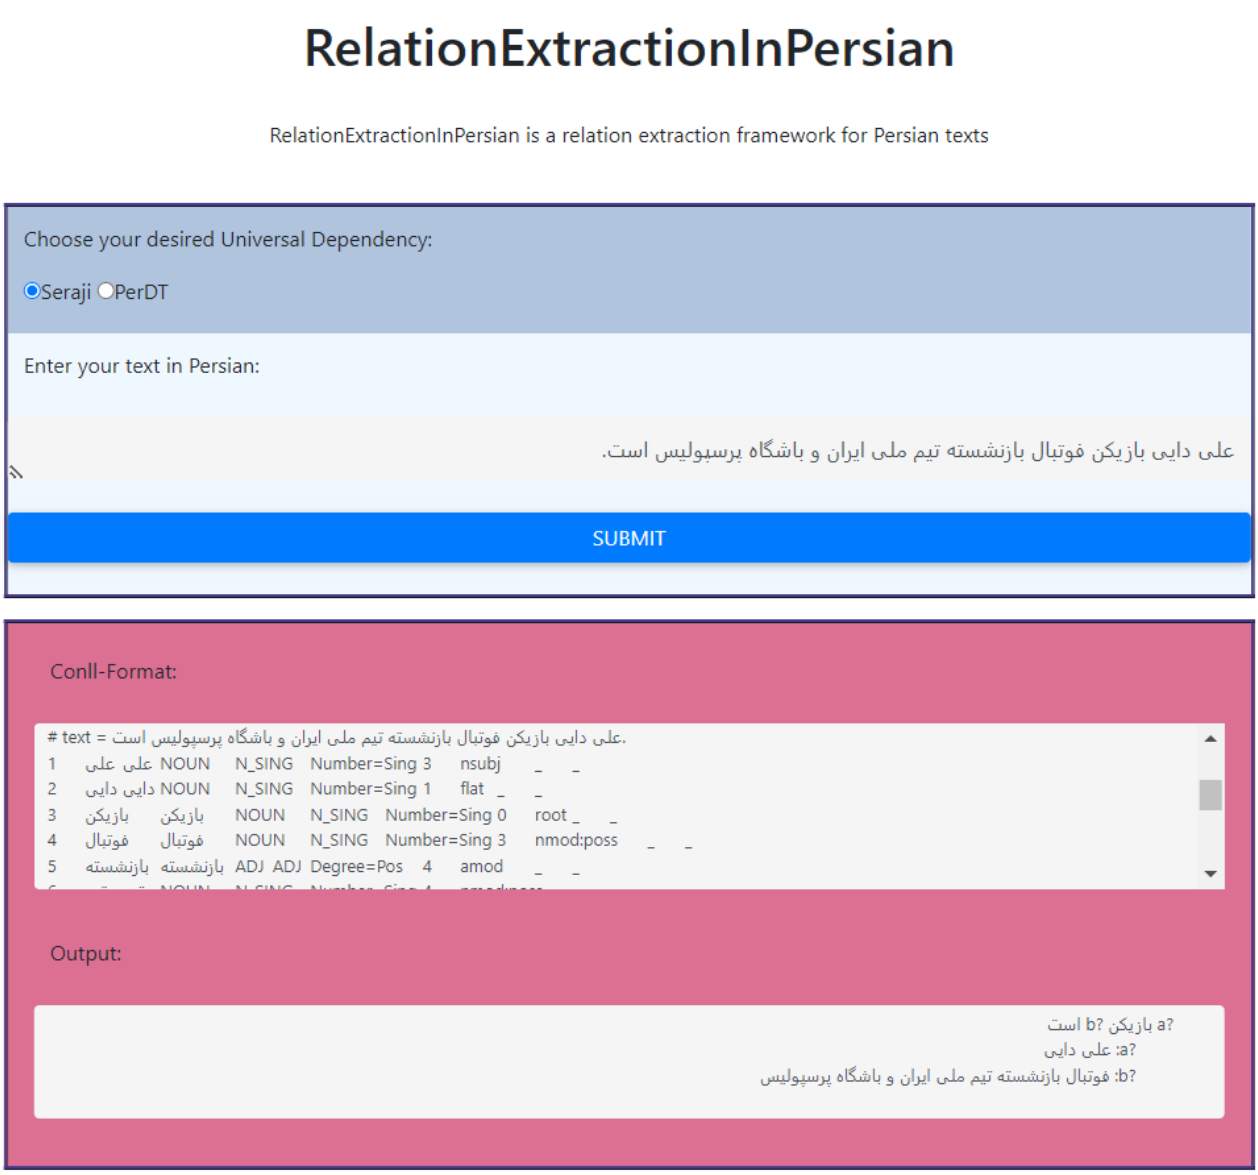

نمونه‌ای از فرایند استخراج رابطه با استفاده از وابستگی جهانی *PerDT*:

RelationExtractionInPersian

RelationExtractionInPersian is a relation extraction framework for Persian texts

Choose your desired Universal Dependency:

○Seraji ◉PerDT

Enter your text in Persian:

علی دایی بازیکن فوتبال بازنشسته تیم ملی ایران و باشگاه پرسپولیس است.

SUBMIT

Conll-Format:

```
# text = علی دایی بازیکن فوتبال بازنشسته تیم ملی ایران و باشگاه پرسپولیس است.
1   علی   علی   PROPN   N_ANM   Number=Sing 3   nsubj   0   3
2   دایی   دایی   PROPN   N_ANM   Number=Sing 1   flat:name 4   8
3   بازیکن   بازیکن   NOUN   N_ANM   Number=Sing 0   root 9   15
4   فوتبال   فوتبال   NOUN   N_IANM   Number=Sing 3   nmod   16   22
5   بازنشسته   بازنشسته   ADJ   ADJ_AJP   None   4   amod   23   31
```

Output:

a? بازیکن b? است
a?: علی دایی
b?: فوتبال بازنشسته تیم ملی ایران و باشگاه پرسپولیس

برای استخراج آرگومان‌های مربوطه به پیاده‌سازی هر دو وابستگی جهانی پرداختیم:

۶/۱ استخراج آرگومان‌ها با استفاده از وابستگی جهانی *Seraji*

در این قسمت، پس از دریافت *ud_type* و *text* از کاربر، در صورتی که کاربر وابستگی جهانی سراجی را انتخاب کرده باشد، اقدام به تولید یک فایل موقتی به نام *file.txt* می‌کنیم. تمامی جملات ورودی را در این فایل می‌ریزیم. سپس اقدام به اجرا کردن یک کامند از طریق *bash* می‌کنیم.

دلیل استفاده از این فایل موقتی به دلیل نیاز این کامند به خواندن اطلاعات از فایل دارد. (*data=@file.txt*) مقدار پارامتر *model* را برابر *persian* قرار دادیم تا از مدل‌های مربوط به زبان فارسی برای استخراج رابطه استفاده شود. از *normalized_space* به عنوان *tokenizer* استفاده می‌کنیم و هم‌چنین برای تجزیه‌گر (پارسر) از *api* ای که برای *udpipe* تعبیه شده است، استفاده می‌کنیم.

در صورتی که اجرای کامند فوق دچار خطا نشود، از کلید *result* در نتایج این دستور می‌توانیم فرمت *conllu* موردنظر را به دست آوریم.

منظور از *Conllu Format* چیست؟

CoNLL نامی معمولی برای قالب‌های *TSV* (مقادیر جدا شده با تب مانند *csv*) در *NLP* است و در واقع فرمتی خاص برای نمایش مقادیر است که در این حوزه بسیار پر کاربرد است. بسیاری از فرمت های مختلف *CoNLL* وجود دارد زیرا *CoNLL* هر سال یک کار مشترک متفاوت است که در کنفرانس سالانه *NLP* تصمیم‌گیری می‌شود. فرمت مشهور آن به این صورت است که:

- هر توکن در یک خط نشان داده می شود.
- هر جمله با یک خط خالی (*NewLine*) از جمله بعدی جدا می شود.
- هر ستون نشان‌دهنده یک *Annotation* است.
- هر کلمه در یک جمله دارای تعداد ستون های یکسانی است. (در برخی قالب ها: هر کلمه در مجموعه تعداد ستون های یکسانی دارد.)

- و... که در این گزارش نمی‌گنجد.

در ادامه، با استفاده از تابع *load_conllu* اقدام به خواندن فرمت *Conll* تولید شده می‌کنیم و تمامی تگ‌های *POS* به‌دست‌آمده و اطلاعات لازم را در یک لیست نگه‌داری می‌کنیم.

به عنوان مرحله نهایی و در قدم آخر، با ورودی دادن این لیست به کلاس *PredPatt* روابط مورد نظر و درخت رابطه ایجاد می‌شود. برای اینکه آرگومان‌های مربوطه را ببینیم، متود *pprint()* را از این کلاس صدا می‌زنیم.

مواردی که در بالا توضیح داده شد، در تصویر زیر قابل مشاهده است:

```
if request.method == "POST":
    ud_type, text = request.POST.get("ud_type"), request.POST.get("input_text")

    if ud_type == 'seraji':
        with open('file.txt', 'w', encoding='utf-8') as f:
            f.write(text.replace('\r', '').strip())
            f.close()

        bash_command = """curl -F data=@file.txt -F model=persian -F tokenizer=normalized_spaces -F tagger= -F
        parser= http://lindat.mff.cuni.cz/services/udpipe/api/process """
        try:
            send_order = subprocess.check_output(bash_command.split(), shell=True)
        except subprocess.CalledProcessError as e:
            os.remove("file.txt")
            raise RuntimeError("command '{}' return with error (code {}): {}".format(e.cmd, e.returncode, e.output))

        os.remove("file.txt")
        conll = json.loads(send_order)['result']
        ppatt = PredPatt([ud_parse for sent_id, ud_parse in load_conllu(conll)][0])
        return render(request, 'service.html',
                      {'input_text': text, 'ud_type': ud_type, 'conll_text': conll, 'output_text': ppatt.pprint()})
```

۶/۲ استخراج آرگومان‌ها با استفاده از وابستگی جهانی *PerDT*

پیاده‌سازی این قسمت در بعضی بخش‌ها مشابه وابستگی جهانی سراجی است. در ابتدا اقدام به دانلود مدل‌های شبکه‌های عصبی موازی برای زبان فارسی می‌کنیم. برای دانلود این مدل‌ها از پکیج *stanza* استفاده می‌کنیم. با استفاده از متود *Pipeline* اقدام به انتخاب شبکه عصبی پیش‌فرض در زبان فارسی می‌کنیم. حال که مدل مربوطه را به دست آوردیم، جمله ورودی را به عنوان ورودی به مدل می‌دهیم.

خروجی مدل تعدادی جملات برای ما خواهد بود که این جملات شامل تعدادی کلمات هستند. در این مرحله بر خلاف روش سراجی که خودش همه نقش‌ها را به ما می‌داد، خودمان باید یکی یکی ویژگی‌های مورد نیاز را به ازای هر کلمه به دست آوریم. ویژگی‌هایی از جمله شناسه، متن کلمه، لم، جایگاه آن در متن، *xpos*، حرف شروع و پایانی و...

تمامی ویژگی‌های مورد نیاز را خودمان دستی تولید می‌کنیم و در قالب یک رشته به همدیگر می‌چسبانیم تا مانند سراجی به PredPatt دهیم تا خروجی را برایمان تولید کند. در واقع، فرمت conll را در اینجا خودمان تولید کردیم و به Predpatt دادیم. بر خلاف روش سراجی که با ران کردن کامند مربوطه این کار را انجام می‌داد.

مواردی که در بالا توضیح داده شد، در تصویر زیر قابل مشاهده است:

```
elif ud_type == "perdt":
    stanza.download('fa')  # This downloads the Persian models for the neural pipeline
    nlp = stanza.Pipeline('fa')  # This sets up a default neural pipeline in Persian
    doc = nlp(text)
    for sentence in doc.sentences:
        res = "# text = " + text.strip()
        res = res.strip() + '\n'
        for word in sentence.words:
            res = res + str(word.id) + "\t" + str(word.text) + "\t" + str(word.lemma) + "\t" + \
                  str(word.pos) + "\t" + str(word.xpos) + "\t" + str(word.feats) + "\t" + \
                  str(word.head) + "\t" + str(word.deprel) + "\t" + str(word.start_char) + "\t" +\
                  str(word.end_char)
            res = res + '\n'

    ppatt = PredPatt([ud_parse for sent_id, ud_parse in load_conllu(res)][0])
    return render(request, 'service.html',
                  {'input_text': text, 'ud_type': ud_type, 'conll_text': res, 'output_text': ppatt.pprint()})
```

۶/۳ به دست آوردن روابط و اجرای وابستگی *Seraji* روی تمامی جملات

در این مرحله، از *API* هایی که در مرحله‌ی قبل برای استخراج آرگومان‌ها با استفاده از وابستگی جهانی سراجی پیاده‌سازی کردیم، استفاده می‌کنیم تا هر یک از آرگومان‌ها را در تمامی جملاتی که داریم، به همراه رابطه‌ی بین این آرگومان‌ها به دست آوریم. در نهایت، دیتاست محدودتری به دست می‌آوریم که شامل تمامی جملاتی است که حداقل یک رابطه در درون خود دارند. (ممکن است تعدادی از جملات طبق مدل *Seraji* اصلا شامل رابطه نباشند.)

ابتدا اقدام به باز کردن فایل جملات و هم‌چنین فایل جملات بعلاوه روابط آنها (برای نوشتن) می‌کنیم. سپس، با استفاده از آدرسی که برای *API* مدل سراجی تعیین کردیم، در حالتی که سرور در حال اجرا باشد، اقدام به ریکوئست زدن می‌کنیم.

```
sentences_file = open('../data/sentence_broken/sentences.json', 'r', encoding='utf8')
results = open('../data/sentence_broken/sentences_with_relations.json', 'w', encoding='utf8')

seraji_request_url = 'http://127.0.0.1:8000/api/seraji'

sentences_json = json.load(sentences_file)

counter = 29000
subject_counter = 2159
error_counter = 0
dataset = []
```

در واقع، روی تک تک جملات دیتاست خود، آنها را به عنوان ورودی *input_text* به *API* مربوطه تحت ریکوئست می‌دهیم. سپس، از خروجی به‌دست‌آمده با استفاده از عملیات مربوط به کار با رشته‌ها در پایتون، ابتدا اطمینان پیدا می‌کنیم که حتما دو آرگومان وجود داشته باشند. (در صورت وجود تک آرگومان، رابطه تعریف نمی‌شود.)

سپس در صورت وجود دو آرگومان، چک می‌کنیم که *subject* صفحه ویکی‌پدیا در آرگومان اول جمله باشد و بالعکس. در صورت وجود، آرگومان دوم را *object* می‌نامیم و تمامی کلمات بین این دو آرگومان را به عنوان رابطه‌ی بین این دو آرگومان در نظر می‌گیریم. (پیش‌تر توضیح داده شد که با استناد به مقاله‌ی *Farsbase pbk* دکتر مینایی این فرض را کرده‌ایم.)

```python
for sentence_dict in sentences_json[29000:]:
    try:
        response = requests.post(seraji_request_url, json={'input_text': sentence_dict['text']})
        output_text = response.json()['output_text']

        subj_index = output_text.find('?a:')
        obj_index = output_text.find('?b:')
        if subj_index != -1 and obj_index != -1:
            subject = output_text[subj_index + 3:obj_index].strip()
            if sentence_dict['subject'] in subject or subject in sentence_dict['subject']:
                object = output_text[obj_index + 3:output_text.find('\n', obj_index + 3)]
                if 'SOMETHING' not in object and len(subject) >= 2:
                    relation = output_text[output_text.find('?a') + 2: output_text.find('?b')]

                    subject = remove_extra_whitespaces(subject)
                    object = remove_extra_whitespaces(object)
                    relation = remove_extra_whitespaces(relation)
                    dataset.append(
                        {
                            'id': subject_counter,
                            'text': sentence_dict['text'],
                            'subject': subject,
                            'object': object,
                            'relation': relation
                        }
                    )
                    subject_counter += 1
                    # if subject_counter >= 6:
                    #     break

                    print('Subject counter: {}'.format(subject_counter))

        counter += 1
        print(str(counter) + " from 31363 (", end='')
        print("%4.2f" % ((counter / 31363) * 100), end='')
        print("%)")

        # if counter >= 29000:
        #     break
    except:
        error_counter += 1
        print('Error #{} occurred!'.format(error_counter))

results.write(json.dumps(dataset, ensure_ascii=False))
results.close()
```

در انتها، با استفاده از تابعی که خودمان تعریف کرده‌ایم (*remove_extra_whitespaces*)، اقدام به حذف فواصل اضافی در ابتدا و انتهای رشته‌ها می‌کنیم و تمامی روابط به‌دست‌آمده را در قالب یک انتیتی داخل لیست *dataset* ذخیره می‌کنیم.

```python
def remove_extra_whitespaces(word):
    if len(word) >= 1:
        if word[0] == ' ':
            word = word[1:]
        if word[-1] == ' ':
            word = word[:-1]

    return word
```

در انتها اقدام به ذخیره‌ی تمامی انتیتی‌های دیتاست در درون یک جیسون واحد در فایل *sentences_with_relations.json* می‌کنیم.

فرمت هریک از موجودیت‌های خروجی به صورت زیر خواهد بود:

```
    {
        "id": 327,
        "text": "شنا باعث کاهش آثار زیان‌بار استرس می‌شود.",
        "subject": "شنا",
        "object": "کاهش آثار زیان‌بار استر",
        "relation": "باعث"
    },
```

```
{
    "id": 82,
    "text": "میلان در اولین دهۀ قرن، یکی از قدرتمندترین باشگاه‌های اروپا و جهان بود.",
    "subject": "میلان",
    "object": "اولین دهۀ قرن",
    "relation": "در"
},
```

```
{
    "id": 67,
    "text": "مجموعه شعرهای احمد شاملو (دوجلدی) در آلمان غربی منتشر می‌شود.",
    "subject": "مجموعه شعرهای احمد شاملو ( دوجلدی)",
    "object": "آلمان غرب",
    "relation": "در"
},
```

همانطور که مشاهده می‌شود، توضیحات پیشین داده‌شده در مورد نتایج به‌دست‌آمده صدق می‌کنند و می‌بینیم که اکثر جملات به درستی آرگومان‌هایشان و روابط بین آن آرگومان‌ها استخراج شده است.

توجه: لازم به ذکر است که برای اجرا کردن این وابستگی جهانی روی جملات، با توجه به تعداد زیاد جملات و طولانی‌شدن فرایند، این کار در ۵ مرحله مجزا انجام گرفته و در نهایت، خروجی‌ها با همدیگر ادغام گشته‌اند و در قالب یک فایل جیسون درآمده‌اند. فایل نهایی شامل مجموعا ۲۳۹۲ روابط استخراج شده از جملات می‌باشد. طبیعتا تعداد زیادی از جملات به دلایلی از جمله عدم وجود آرگومان، تک آرگومانی، نبودن موضوع در آرگومان اول و... حذف شده‌اند و مقادیری باقی مانده اند که بتوانیم در بخش‌های بعدی از آنها استفاده کنیم.

تصاویر زیر، نمایانگر مراحلی از اجرای کد مربوطه روی جملات هستند. تصویر اول پیشروی ریکوئست‌ها به ازای هر جمله را نشان می‌دهد و تصویر دوم نیز اطلاعاتی در مورد سرعت آپلود و دانلود و... در ازای هر بار دستیابی به مدل *Conllu* با استفاده از دستور اجرایی در *bash* می‌باشد. (این عملیات با صدا زدن *API* مربوط به سرویس *udpipe* انجام می‌گیرد.)

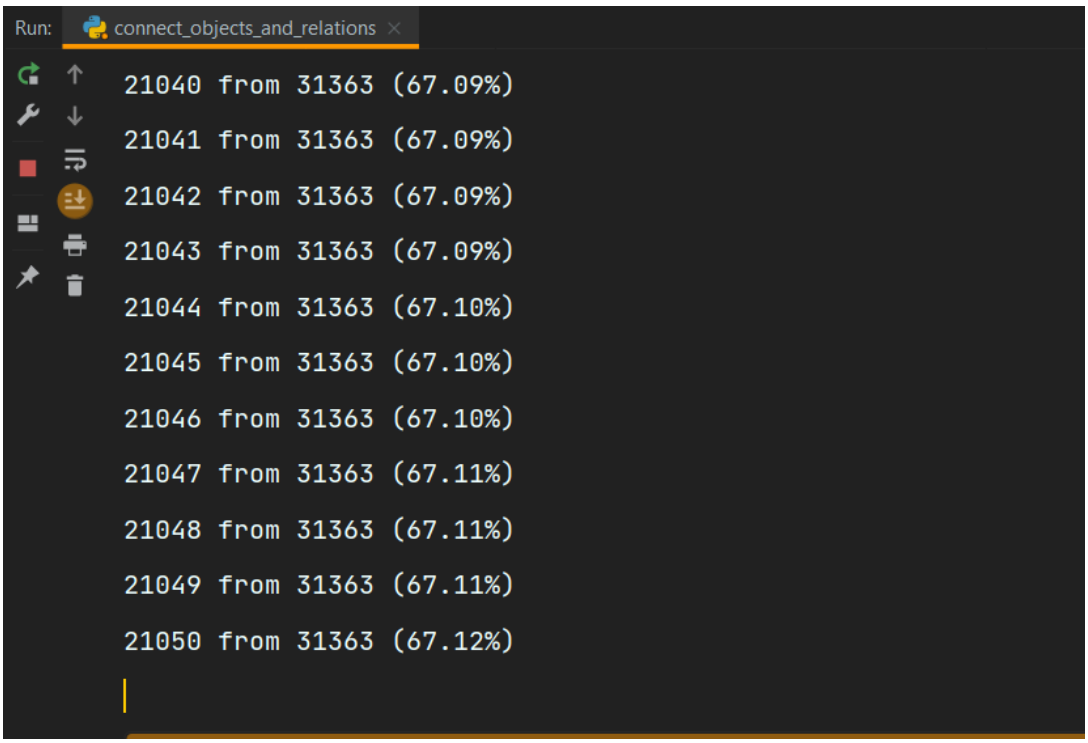

```
Terminal:  Local  +
[10/Jul/2022 04:12:22] "POST /api/seraji HTTP/1.1" 200 3244
  % Total    % Received % Xferd  Average Speed   Time    Time     Time  Current
                                 Dload  Upload   Total   Spent    Left  Speed
100  4794    0  3803  100   991   6703   1746 --:--:-- --:--:-- --:--:--  8484
[10/Jul/2022 04:12:22] "POST /api/seraji HTTP/1.1" 200 4325
  % Total    % Received % Xferd  Average Speed   Time    Time     Time  Current
                                 Dload  Upload   Total   Spent    Left  Speed
100  2805    0  2029  100   776   4362   1668 --:--:-- --:--:-- --:--:--  6058
[10/Jul/2022 04:12:23] "POST /api/seraji HTTP/1.1" 200 1913
  % Total    % Received % Xferd  Average Speed   Time    Time     Time  Current
                                 Dload  Upload   Total   Spent    Left  Speed
  0     0    0     0    0     0      0      0 --:--:-- --:--:-- --:--:--     0
```

۷ *BERT*

۷٫۱ *ParseBERT* چیست؟

موج مدل‌های زبانی از پیش آموزش‌دیده، عصر جدیدی را در زمینه پردازش زبان طبیعی (*NLP*) آغاز کرده است و به ما امکان ساخت مدل‌های زبان قدرتمند را می‌دهد. در میان این مدل‌ها، مدل‌های مبتنی بر ترانسفورماتور مانند *BERT* به دلیل عملکرد پیشرفته‌ای که دارند، محبوبیت فزاینده‌ای پیدا کرده‌اند. با این حال، این مدل ها معمولاً بر زبان انگلیسی متمرکز هستند و زبان های دیگر را به مدل های چند زبانه با منابع محدود واگذار می کنند.

این مقاله یک *BERT* تک زبانه برای زبان فارسی (*ParsBERT*) پیشنهاد می‌کند که عملکرد پیشرفته آن را در مقایسه با سایر معماری‌ها و مدل‌های چند زبانه نشان می‌دهد. همچنین از آنجایی که حجم داده‌های موجود برای وظایف *NLP* در زبان فارسی بسیار محدود است، مجموعه داده‌ای عظیم برای وظایف مختلف *NLP* و همچنین پیش‌آموزش مدل تشکیل شده است.

ParsBERT در تمام مجموعه‌های داده، از جمله مجموعه‌های موجود و همچنین مجموعه‌های ترکیبی، امتیازهای بالاتری به دست می‌آورد و با پیشی گرفتن از *BERT* چند زبانه و سایر کارهای قبلی در وظایف تحلیل احساسات، طبقه‌بندی متن و شناسایی موجودیت نام‌گذاری، عملکرد پیشرفته را بهبود می‌بخشد.

۷/۲ استفاده از *ParseBERT* در زبان فارسی

دستاوردهای زیادی در زمینه زبان طبیعی برای زبان انگلیسی یا حتی زبان های دیگر وجود دارد، اما در مورد فارسی، همانطور که می بینید، این دستاوردها زیاد نیست. شاید کمبود منابع داده ای، عدم افشای منابع توسط گروه های پژوهشی و جوامع غیرمتمرکز پژوهشی دلایل اصلی وضعیت فعلی فارسی باشد.

البته لازم به ذکر است که برخی از گروه های پژوهشی به این موضوع توجه دارند و نتایج، افکار و منابع خود را با دیگران به اشتراک می گذارند، اما همچنان به موارد بیشتری نیاز داریم.

زبان طبیعی ابزاری است که انسان ها برای برقراری ارتباط با یکدیگر از آن استفاده می کنند. بنابراین، حجم وسیعی از داده ها به عنوان متن با استفاده از این ابزار کدگذاری می شوند. استخراج اطلاعات معنی دار از این نوع داده ها و دستکاری آنها با استفاده از رایانه در حوزه پردازش زبان طبیعی (*NLP*) قرار دارد.

وظایف *NLP* مختلفی مانند شناسایی نهاد نامگذاری شده (*NER*)، تجزیه و تحلیل احساسات (*SA*) و پرسش/پاسخ وجود دارد که هر کدام بر جنبه خاصی از داده های متنی تمرکز می کنند تا به عملکرد موفقیت آمیز در هر یک از این وظایف دست پیدا کنند. در سال های اخیر روش های آموزش تعبیه واژه و مدل سازی زبان پیشنهاد شده است.

۷/۳ روش استفاده

در این بخش، روش مدل پیشنهادی ما ارائه شده است. این شامل پنج وظیفه اصلی است که سه وظیفه اول مربوط به مجموعه داده و دو وظیفه بعدی مربوط به توسعه مدل است.
این وظایف عبارتند از جمع آوری داده ها، پیش پردازش داده ها، تقسیم بندی دقیق جملات، تنظیم قبل از آموزش و تنظیم دقیق.

۷/۳/۱جمع آوری داده:

اگرچه چند مجموعه متن فارسی توسط دانشگاه لایپزیگ و دانشگاه سوربن ارائه شده است، اما جملات موجود در آن مجموعه‌ها از نظم منطقی در سطح مجموعه پیروی نمی‌کنند و تا حدودی اشتباه هستند. همچنین، این منابع تنها تعداد محدودی از سبک ها و موضوعات نوشتاری را پوشش می دهند.

بنابراین، برای افزایش کلیت و کارایی مدل از پیش آموزش‌دیده ما در سطوح کلمات، عبارات و جملات، لازم بود شکل جدیدی از پیکره را از ابتدا برای مقابله با محدودیت‌هایی که قبلاً ذکر شد، ایجاد کنیم. این کار با خزیدن در بسیاری از منابع مانند ویکی پدیای فارسی انجام شد.

۷/۳/۲پیش پردازش داده:

پس از جمع‌آوری مجموعه پیش‌آموزشی، سلسله مراتب عظیمی از مراحل پردازش، از جمله تمیز کردن، جایگزینی، پاک‌سازی، و عادی‌سازی ، برای تبدیل مجموعه داده‌ها به یک قالب مناسب حیاتی است.

۷/۳/۳بخش بندی متن:

پس از اینکه مجموعه از پیش پردازش شد، باید به جملات واقعی مربوط به هر سند تقسیم شود تا نتایج قابل توجهی برای مدل پیش‌آموزشی حاصل شود. یک جمله واقعی در فارسی بر اساس این نمادها تشخیص داده می شود.

با این حال، تقسیم محتوا صرفاً بر اساس این نمادها نشان داده است که مشکلاتی ایجاد می کند. در شکل ۲، نمونه ای از این مسائل نشان داده شده است. می توان مشاهده کرد که نتیجه شامل جملات کوتاه بی معنی و بدون هیچ گونه اطلاعات حیاتی است، زیرا در زبان فارسی اختصاراتی وجود دارد که با علامت نقطه (.) از هم جدا شده اند.

به عنوان یک جایگزین، *Part Of Speech (POS)* می تواند راه حل مناسبی برای رسیدگی به این نوع خطاها و تولید خروجی های دلخواه باشد. این روش سیستم را قادر می سازد تا رابطه واقعی بین جملات هر سند را بیاموزد.

۷/۳/۴ *Pre-training*

مدل ما بر اساس معماری مدل *BERT* است که شامل یک ترانسفورماتور دو طرفه چند لایه است.

۷/۳/۵ مدل‌سازی نهایی

مدل زبان نهایی (مدل پیشنهادی ما) باید با وظایف مختلفی تنظیم شود: تجزیه و تحلیل احساسات، طبقه بندی متن، و شناسایی موجودیت نامگذاری شده.

تجزیه و تحلیل احساسات و طبقه بندی متن متعلق به یک کار گسترده تر به نام طبقه بندی توالی است. تجزیه و تحلیل احساسات به عنوان یک وظیفه خاص طبقه بندی متن در بازنمایی احساسات پشت متن شناخته می شود.

۷/۴ پیاده سازی

برای پیاده سازی ، از کتابخانه *sentence_transformers* استفاده می کنیم.همچنین برای *cluster* بندی کردن، از کتابخانه *sklearn* استفاده می کنیم.

سپس با خواندن جمله های به دست آمده در مراحل قبلی پروژه ، جملات را می خوانیم و با انجام عملیات های زیر، جملات جدیدی تولید می شوند که در فایل *bert_sentence.json* مشاهده می شوند.

قطعه کد زیر مربوط به مدل بندی کردن با استفاده از *sentence_transformer* است.

```
def load_st_model(model_name_or_path):
    word_embedding_model = models.Transformer(model_name_or_path)
    pooling_model = models.Pooling(
        word_embedding_model.get_word_embedding_dimension(),
        pooling_mode_mean_tokens=True,
        pooling_mode_cls_token=False,
        pooling_mode_max_tokens=False)

    model = SentenceTransformer(modules=[word_embedding_model, pooling_model])
    return model

```

در نهایت با اجرای قطعه کد زیر ، عملیات *cluster* بندی کردن به اتمام می رسد و جملات جدید تولید می شوند.

```python
# Perform kmean clustering
clustering_model = KMeans(n_clusters=num_clusters)
clustering_model.fit(corpus_embeddings)
cluster_assignment = clustering_model.labels_

clustered_sentences = [[] for i in range(num_clusters)]
for sentence_id, cluster_id in enumerate(cluster_assignment):
    clustered_sentences[cluster_id].append(corpus[sentence_id])

for i, sentences in enumerate(clustered_sentences):
    rtl_print(f'Cluster: {i + 1}', '20px')
    rtl_print(sentences)
    rtl_print('- - ' * 50)
    bert_sentence.append({
        'id': i,
        'text': sentences
    })

```

نمونه هایی از جملات تولید شده را در زیر مشاهده می کنید:


```
{
    "id": 1,
    "text": "."آنان هرشب بر روی صحنه می‌رفتند و می‌درخشیدند اما به جای تشویق و دسته‌های گل، سنگ و کلوخ و ناسزا دریافت می‌کردند
},
{
    "id": 2,
    "text": "ا هر هویدا در سال ۱۹۹۰ (میلادی) به آلمان پناهنده شد و مدت ۱۷ سال را در آنجا گذراند و در آن دیار به کارهای هنری خود ادامه داد
{
    "id": 3,
    "text": "ک کمدی-درام به نویسندگی و کارگردانی الن سایدلر و مگان سایلر محصول سال ۲۰۰۹ است (انگلیسی: And Then Came Lola) و سپس لولا آمد
},
{
    "id": 4,
    "text": "."برای نمونه سیکلواکتاتترائنید دی‌آنیون چنین است

},
{
    "id": 5,
    "text": "را ملاقات می‌کنند و یک روز خاص را صرف با هم بودن می‌کنند، است؛ که توسط another parting او سپس با بازی در مینی سریال پنج قسمتی

},
{
    "id": 6,
    "text": "."وی در طول جنگ در عملیات‌های طریق‌القدس، فتح‌المبین، بیت‌المقدس، رمضان، والفجر ۴، بدر و والفجر ۸، حضوری فعال داشت",

},
{
    "id": 7,
    "text": "ن خانوادهٔ پیامبر، به‌عنوان حافظ ایمان اسلامی و به‌عنوان تنها حاکمانی که تداوم‌بخش آرمان سلطنتی ایرانی بودند، حکمرانی می‌کردند
```

۸ Training

در نهایت برای *train* کردن داده ها، ابتدا با استفاده از قطعه کد زیر، به آن می گوییم که ۸۰ درصد داده هایمان برای *train* است و ۲۰ درصد برای تست:

```
from transformers import AutoConfig, AutoTokenizer, AutoModel
from sklearn import datasets
from sklearn.model_selection import train_test_split

wine = datasets.load_wine('../data/cleaned/cleaned_dataset.json')
X = wine.data
print(X.shape)

y = wine.target
print(y.shape)

dX_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)
#80 percent training
#20 percent test
```

سپس ابتدا با *train* کردن ۸۰ درصد (*trainig*) روابط بین *entity* ها به دست می آیند.

برای قسمت تست، بین ۲۰ درصد جمله های خود که در واقع تقریبا ۶۰۰ تا می باشد، آن ها را با کد قسمت قبل که روابز را به دست می آورد و همچنین یک بار دیگر بر اساس *relation* های به دست آمده در *training*، و احتمال آن ها محاسبه می کنیم و در نهایت دقتت و *loss* زیر به دست می آید:

trn_loss	val_loss	accuracy
1.22288	0.531899	0.895833
0.728065	0.22854	0.947917
0.521159	0.24	0.942708
0.436836	0.278884	0.9375
0.367163	0.296403	0.9375
0.299235	0.316672	0.9375
0.265763	0.326505	0.932292